



УНИВЕРЗИТЕТ У НОВОМ САДУ
ФАКУЛТЕТ ТЕХНИЧКИХ
НАУКА У НОВОМ САДУ



Развој и вишедимензионална класификација
система вјештачке интелигенције
са примјеном модела FinBERT у анализи
сентимента вијести о мрежи Ethereum

-- Дипломски рад --

Основне академске студије

Кандидат:

Алекса Грубачић

ЕМ 12/2014

Ментор:

Проф. Др Платон Сивиљ

Нови Сад, 2026



УНИВЕРЗИТЕТ У НОВОМ САДУ • ФАКУЛТЕТ ТЕХНИЧКИХ НАУКА
21000 НОВИ САД, Трг Доситеја Обрадовића 6

КЉУЧНА ДОКУМЕНТАЦИЈСКА ИНФОРМАЦИЈА

Редни број, РБР:	
Идентификациони број, ИБР:	
Тип документације, ТД:	Монографска документација
Тип записа, ТЗ:	Текстуални штампани документ
Врста рада, ВР:	Дипломски (Bachelor) рад
Аутор, АУ:	Алекса Грубачић
Ментор, МН:	Др Платон Сивиљ
Наслов рада, НР:	Развој и вишедимензионална класификација система вјештачке интелигенције са примјеном модела FinBERT у анализи сентимента вијести о мрежи Ethereum
Језик публикације, ЈП:	Српски
Језик извода, ЈИ:	Српски
Земља публикавања, ЗП:	Република Србија
Уже географско подручје, УГП:	Аутономна покрајина Војводина
Година, ГО:	2026.
Издавач, ИЗ:	Ауторски репринт
Место и адреса, МА:	Нови Сад, Трг Доситеја Обрадовића бр. 6.
Физички опис рада, ФО: (поглавља/страна/ цитата/табела/слика/графика/прилога)	
Научна област, НО:	
Научна дисциплина, НД:	
Предметна одредница/Кључне речи, ПО:	
УДК	
Чува се, ЧУ:	Библиотека Факултета техничких наука
Важна напомена, ВН:	
Извод, ИЗ:	У раду су приказани историјски развој и вишедимензионална класификација вјештачке интелигенције, а затим испитана додатна обука FinBERT-а за класификацију Ethereum вијести према ознакама тржишног правца изведеног из гласова корисника. На Ethereum подскупу од 4.721 вијести из скупа DLT-Sentiment-News модел је упоређен са оригиналним FinBERT-ом и TF-IDF логистичком регресијом. Макро F1 додатно обученог модела износио је 0,5761 на насумичној и 0,4265 на временској подјели. Побољшање је било мање при тестирању на каснијим вијестима.
Датум прихватања теме, ДП:	
Датум одбране, ДО:	
Чланови комисије, КО: Председник:	
Члан:	
Члан, ментор:	
	Потпис ментора



UNIVERSITY OF NOVI SAD • FACULTY OF TECHNICAL SCIENCES
21000 NOVI SAD, Trg Dositeja Obradovića 6

KEY WORDS DOCUMENTATION

Accession number, ANO :	
Identification number, INO :	
Document type, DT :	Monographic documentation
Type of record, TR :	Textual print material
Contents code, CC :	Bachelor thesis
Author, AU :	Aleksa Grubacic
Mentor, MN :	Professor Platon Sovilj, PhD
Title, TI :	Development and Multidimensional Classification of Artificial Intelligence Systems, with an Application of the FinBERT Model to Sentiment Analysis of Ethereum Network News
Language of text, LT :	Serbian
Language of abstract, LA :	Serbian / English
Country of publication, CP :	Republic of Serbia
Locality of publication, LP :	AP of Vojvodina
Publication year, PY :	2026
Publisher, PB :	Author's reprint
Publication place, PP :	21000 Novi Sad, Trg Dositeja Obradovica 6
Physical description, PD : (chapters/pages/ref./tables/pictures/graphs/appendixes)	
Scientific field, SF :	
Scientific discipline, SD :	
Subject/Key words, S/KW :	
UC	
Holding data, HD :	Library of Faculty of Technical Sciences, Novi Sad
Note, N :	
Abstract, AB :	his thesis reviews the historical development and multidimensional classification of artificial intelligence, then evaluates additional FinBERT training for classifying Ethereum news into labels derived from user votes. A subset of 4,721 Ethereum-related items was selected from DLT-Sentiment-News. The fine-tuned model was compared with the original FinBERT and a TF-IDF logistic-regression baseline. Its mean macro-F1 was 0.5761 on the random split and 0.4265 on the chronological split. The improvement was smaller when evaluated on later news.
Accepted by the Scientific Board on, ASB :	
Defended on, DE :	
Defended Board, DB : President:	
Member:	
Member, Mentor:	
	Mentor's sign

Садржај

1	Увод	5
2	Настанак и историјски развој вјештачке интелигенције	6
2.1	Теоријске основе	6
2.2	Симболички период	6
2.3	AI зиме и промјена истраживачког правца	8
2.4	Успон машинског и дубоког учења	8
3	Појам и границе вјештачке интелигенције	10
3.1	Проблем јединствене дефиниције	10
3.2	Однос AI, машинског учења и дубоког учења	10
3.3	AI систем, модел и апликација	11
4	Класификација вјештачке интелигенције	12
4.1	Класификација према способностима	12
4.1.1	Уска вјештачка интелигенција – ANI	12
4.1.2	Општа вјештачка интелигенција – AGI	12
4.1.3	Суперинтелигенција – ASI	13
4.1.4	Ограничења ове подјеле	13
4.2	Класификација према техникама и начинима учења	14
4.2.1	Симболичка вјештачка интелигенција	14
4.2.2	Машинско учење	15
4.2.3	Неуронске мреже и дубоко учење	15
4.2.4	Обрада природног језика и трансформер модели	16
4.2.5	Генеративни модели према врсти излаза	16
4.2.6	Еволутивни алгоритми и рачунарска интелигенција	17
4.2.7	Фази системи	17
4.2.8	Хибридна и неуро-симболичка AI	18
4.2.9	Поређење техничких приступа	18
4.3	Класификација према улози у одлучивању и степену аутономије	19
4.3.1	Асистивни системи	19
4.3.2	Аутономни системи	19
4.3.3	Степен аутономије	19
4.4	Класификација према окружењу имплементације	20
4.4.1	Извршавање у рачунарском облаку	20
4.4.2	Извршавање на рубним уређајима	20
4.4.3	Уграђена вјештачка интелигенција	20
5	Повезивање критеријума у вишедимензионалну подјелу	21
6	Практични дио рада	23
6.1	Анализа финансијског сентимента (Financial Sentiment Analysis — FSA)	23
6.1.1	Увод и дефиниција	23
6.1.2	Еволуција техника — од рјечника до великих језичких модела	23
6.1.3	Примјене FSA у финансијском сектору	24
6.1.4	Закључак и будући правци примјене вјештачке интелигенције за FSA	25
6.2	Теоријска основа	25

6.2.1	BERT и трансформерска архитектура	25
6.2.2	FinBERT	25
6.2.3	Додатна обука модела	26
6.3	Циљ и истраживачко питање	26
6.4	Скуп података и припрема	26
6.5	Ознаке и припрема улаза	27
6.6	Поставка пројекта	28
6.7	Мјерила успјешности и статистичко поређење	28
6.8	Резултати	28
6.8.1	Поређење модела	28
6.8.2	Варијабилност између вриједности параметра seed	29
6.8.3	McNemar-ов тест	30
6.8.4	Матрице конфузије	31
6.9	Дискусија	31
6.10	Ограничења	33
6.11	Поновљивост и структура резултата	33
7	Закључак	34
8	Списак слика и табела	35
9	Литература	36

1 Увод

Вјештачка интелигенција представља једну од најзначајнијих области савременог технолошког развоја. Иако се о њој данас говори као о јединственој и препознатљивој технологији, вјештачка интелигенција у стварности обухвата велики број различитих метода, модела, система и области примјене. Системи вјештачке интелигенције могу бити засновани на формалној логици и унапријед дефинисаним правилима, на статистичком учењу из података, на неуронским мрежама, на еволутивним алгоритмима или на комбинацији више различитих приступа. Због тога израз „вјештачка интелигенција“ означава заправо широку истраживачку и инжењерску област [18].

Развој ове области одвијао се кроз више историјских етапа. Рани системи били су углавном засновани на симболичком представљању знања, логичком закључивању и ручно дефинисаним правилима. Каснији развој машинског учења помјерио је тежиште са експлицитног програмирања правила на учење образаца из података. Напредак неуронских мрежа, доступност великих скупова података и развој хардвера додатно су убрзали развој дубоког учења. У новије вријеме, трансформер архитектуре, велики језички модели и генеративна вјештачка интелигенција проширили су могућности система за обраду језика, слике, звука и других облика података.

Појмови вјештачка интелигенција, машинско учење, дубоко учење и генеративна вјештачка интелигенција често се користе заједно, иако означавају различите нивое или аспекте исте области. Вјештачка интелигенција представља најшири појам. Машинско учење односи се на методе које омогућавају систему да на основу података научи образце потребне за доношење предвиђања или одлука. Дубоко учење представља подскуп машинског учења који се ослања на вишеслојне неуронске мреже. Генеративна вјештачка интелигенција означава системе који, на основу научених образаца, могу да стварају нови текст, слике, звук, програмски код или друге врсте садржаја.

У овом раду вјештачка интелигенција посматра се кроз неколико основних критеријума: способности, технички приступ, улогу у одлучивању, степен аутономије и окружење имплементације. Приступом класификације постојећих система настоји се обухватити и боље разумети ова богата грана технологије. Оваква подјела није јединствена таксономија, већ представља синтезу више приступа из литературе [22]. Сваки критеријум одговара на друго питање: способности описују ширину задатака, технички приступ архитектуру и начин на који модел учи, док улога, аутономија и окружење одређују начин примјене модела у систему. Комбиновањем ових критеријума може се прецизно описати модел за анализу сентимента из практичног дијела рада. Први дио рада обухвата кратак историјски преглед развоја вјештачке интелигенције, од симболичких и експертних система до машинског учења, дубоког учења и савремених језичких модела. Посебна пажња посвећена је важним моделима и архитектурама, као што су перцептрон, неуронске мреже, AlexNet и Transformer. Теоријски оквир на крају припрема основу за практични дио рада у коме се испитује да ли модел FinBERT може боље да препозна позитиван, негативан или неутралан став у вестима о Ethereum-у након додатне обуке на примјерима из те области.

2 Настанак и историјски развој вјештачке интелигенције

2.1 Теоријске основе

Теоријске основе вјештачке интелигенције формирале су се средином двадесетог вијека, у периоду развоја првих електронских рачунара и формалних метода за описивање рачунања. Један од најважнијих доприноса дао је Алан Тјуринг у раду *Computing Machinery and Intelligence* из 1950. године [27]. Умјесто да покушава да понуди строгу дефиницију појма мишљења, Тјуринг предлаже практичан тест заснован на понашању: испитивач води текстуални разговор и са човјеком и са машином, не знајући ко је ко. Ако машина успије да наведе испитивача да повјерује да разговара са човјеком, сматра се да показује интелигентно понашање.

Овај приједлог познат је као Тјурингов тест, односно игра имитације. У основној поставци, испитивач комуницира са човјеком и машином без директног увида у њихов идентитет, а затим покушава да утврди ко је дао који одговор. Тјурингов тест није замишљен као потпуна мјера интелигенције нити као доказ да машина посједује људску свијест. Његов историјски значај огледа се у томе што је отворио могућност да се интелигентно понашање проучава преко мјерљивих резултата.

Други важан тренутак представља приједлог за Дартмаутску љетњу истраживачку радионицу из 1955. године, коју су припремили Џон Мекарти, Марвин Мински, Натанијел Рочестер и Клауд Шанон. Радионица је одржана 1956. године и често се наводи као догађај којим је вјештачка интелигенција обликована као посебна истраживачка област. У приједлогу је изнесена претпоставка да се сваки аспект учења или други облик интелигенције може, барем у начелу, довољно прецизно описати тако да га машина може симулирати. Ова претпоставка усмјерила је ране истраживаче према проблемима као што су закључивање, коришћење језика, рјешавање проблема и учење [14].

Рани приступ вјештачкој интелигенцији био је снажно повезан са математиком, логиком и теоријом рачунања. Истраживачи су полазили од идеје да се сложено понашање може представити помоћу симбола, правила и поступака за њихово комбиновање. Ако се знање може записати формалним језиком, а поступак закључивања изразити као низ јасно дефинисаних операција, рачунар може извршавати такве поступке и рјешавати проблеме који се повезују са интелигентним понашањем. Овакво размишљање касније је довело до развоја симболичке вјештачке интелигенције и експертних система.

У овој раној фази очекивања су била веома велика. Вјеровало се да би, уз довољно прецизно представљање знања и одговарајуће алгоритме, рачунари могли да рјешавају широк распон проблема. Ипак, каснији развој показао је да формализовање свакодневног знања, неизвјесности и контекста представља много сложенији задатак него што се првобитно претпостављало. Због тога су теоријске основе из овог периода важне и као почетак развоја AI и као основа за разумијевање ограничења раних симболичких система. Сљедеће поглавље детаљније разматра управо тај симболички период.

2.2 Симболички период

Симболичка вјештачка интелигенција представља један од првих доминантних приступа у развоју ове области [18]. Њена основна претпоставка јесте да се знање и поступци закључивања могу представити помоћу симбола, правила и формалних језика. За разлику од савремених модела који обрасце најчешће уче из великих скупова података, симболички системи се ослањају на експлицитно записано знање и унапријед

дефинисана правила.

У симболичким системима знање се обично чува у облику чињеница, односа и правила. Правила могу имати облик условних исказа, на примјер: ако су испуњени одређени услови, онда треба извести одређени закључак. Посебан дио система, познат као механизам закључивања, примјењује та правила на доступне чињенице. На тај начин систем може да претражује могуће закључке, рјешава логичке проблеме или предлаже одлуке у ограниченом домену.

Један од раних и историјски значајних примјера јесте Логички теоретичар, развијен средином 1950-их година [15], [16]. Овај програм су развили Њуел, Сајмон и Шо [15], [16] са циљем да демонстрирају да рачунар може да извршава поступке сличне људском логичком закључивању. Програм је био намијењен доказивању математичких теорема и користио је симболичко представљање проблема и претраживање могућих корака ка рјешењу. Његов значај није само у конкретним доказима, већ и у идеји да се рјешавање проблема може описати као поступак претраге и манипулисања симболима.

Каснији развој довео је до експертних система, који су покушавали да знање стручњака пренесу у рачунарски програм. Експертни систем обично се састојао од базе знања и механизма закључивања [18]. База знања садржала је чињенице и правила из одређене области, док је механизам закључивања користио та правила за извођење закључака на основу података које је корисник уносио. Оваква структура омогућила је да систем у ограниченом домену даје препоруке и објашњења налик поступку људског стручњака.

Познат примјер је MYCIN, експертни систем развијен на Универзитету Станфорд током 1970-их година [23]. MYCIN је био намијењен подршци при препознавању одређених бактеријских инфекција и избору одговарајуће антибиотске терапије. Систем је користио скуп медицинских правила, а при доношењу закључака узимао је у обзир и степен сигурности појединих процјена. Иако није био замишљен као замјена за љекара, MYCIN је показао да симболички систем може да обједини знање из уске области и да своје закључке представи кроз низ разумљивих правила.

Највећа предност симболичке вјештачке интелигенције била је могућност релативно јасног праћења процеса закључивања. Када систем донесе закључак, корисник може да види која су правила примијењена и на којим чињеницама се закључак заснива. То је посебно значајно у областима у којима је потребно образложити одлуку. Симболички системи такође могу добро функционисати када је домен јасно дефинисан, а знање може прецизно да се изрази правилима.

Као један од најпознатијих успјеха рачунарског претраживања издваја се ИБМ-ов систем Deep Blue, који је 1997. године победио свјетског шампиона у шаху Гарија Каспарова користећи процјену позиција и систематско претраживање великог броја могућих потеза [3].

Ипак, овај приступ има озбиљна ограничења. Ручно прикупљање и записивање знања захтијева много времена и зависи од доступности стручњака. Правила могу постати веома бројна и међусобно сложена, па њихово одржавање постаје тешко. Симболички системи такође имају потешкоће са непотпуним, нејасним и контрадикторним информацијама, као и са ситуацијама које нису унапријед предвиђене. Због тога су рани системи често били успјешни у уским областима, али нису могли лако да се прилагоде новим проблемима или да знање пренесу у други домен.

Упркос тим ограничењима, симболички приступ поставио је важне темеље за развој експертних система, обраде знања, планирања и аутоматског закључивања. Каснији развој машинског учења понудио је другачији начин изградње система: умјесто да се сва правила ручно задају, модел учи обрасце из података.

2.3 AI зиме и промјена истраживачког правца

Развој вјештачке интелигенције није текао равномјерно током протеклих седам-десетак година. Периоди великог оптимизма и високих очекивања смјењивали су се са периодима разочарања, смањеног финансирања и самим тим слабијег интересовања истраживачке заједнице. Такви периоди познати су као AI зиме. Од истраживања се није потпуно одустало, већ се њихов интензитет смањивао [26].

Један од главних узрока првих проблема био је несклад између очекивања и тадашњих техничких могућности. Рани програми вјештачке интелигенције успјешно су рјешавали поједностављене проблеме у ограниченим условима, али су се тешко сналазили када је требало обрадити сложеније и непредвидиве ситуације. Системи који су радили са малим скупом правила нису могли лако да се прилагоде новим примјерима, непотпуним информацијама и промјенама у окружењу.

Током 1970-их година постало је јасно да ограничена рачунарска снага представља озбиљну препреку за развој сложенијих система. Осим што су рачунари били слабији, велике базе података потребне за развој AI система углавном нису биле доступне у облику погодном за аутоматску обраду. Оваква ограничења допринијела су смањењу финансирања и настанку прве AI зиме.

Други талас разочарања уследио је током касних 1980-их и почетком 1990-их. У том периоду, велика пажња била је посвећена експертним системима, који су знање приказивали кроз велики број ручно дефинисаних правила. Иако су такви системи могли да дају корисне резултате у уско одређеним областима, њихово развијање и одржавање било је скупо. Свака промјена у области захтијевала је додатно прикупљање знања и ручно прилагођавање правила. Поред тога, системи су се тешко носили са контрадикторним подацима и ситуацијама које нису биле предвиђене приликом њиховог пројектовања.

Искуство са AI зимама показало је да сама сложеност правила није довољна за изградњу интелигентног система. Проблем није био само у броју правила, већ и у томе што је било тешко унапријед описати све околности у којима ће пројектовани систем радити. Због тога се истраживачки интерес постепено помјерао ка методама које могу да уче из примјера. Умјесто да програмер ручно дефинише сваку везу између улаза и излаза, модел покушава да пронађе правилности у доступним подацима.

Овај заокрет представља основу статистичког машинског учења. У таквом приступу модел се обучава на скупу података и на основу њега подешава своје параметре. Квалитет система зато зависи од количине, структуре и поузданости података, али и од изабране методе учења. Статистички модели нису уклонили потребу за људским знањем, али су омогућили да се дио знања изгради аутоматски, кроз обраду већег броја примјера.

Промјена истраживачког правца постала је нарочито значајна када су истовремено напредовали рачунарски хардвер, прикупљање података и алгоритми машинског учења. Тиме су створени услови за успјешнију примјену неуронских мрежа и развој дубоког учења. Наредна етапа обухвата перцептрон, алгоритам повратног простирања грешке, коришћење графичких процесора и моделе који су показали да се сложене репрезентације могу научити директно из података.

2.4 Успон машинског и дубоког учења

Прелазак са ручно дефинисаних правила на учење из података довео је до поновног развоја неуронских мрежа. Неуронска мрежа састоји се од међусобно повезаних јединица које обрађују улазне податке и постепено формирају сложеније репрезентације. Током обучавања, параметри мреже мијењају се тако да се смањује разлика између

предвиђеног и жељеног излаза. На тај начин модел може да научи правилности које нису унапријед записане у облику експлицитних правила.

Један од првих значајних модела ове врсте био је перцептрон, који је крајем 1950-их представљен као једноставан модел за класификацију. Перцептрон прима више улазних вриједности, додјељује им тежине и на основу њихове комбинације доноси одлуку о припадности одређеној класи. Иако је имао ограничене могућности и није могао да ријеши све врсте проблема, перцептрон је показао да се одређени елементи одлучивања могу научити из примјера. Његов значај је зато већи од непосредне практичне примјене, јер је послужео као основа за касније сложеније неуронске мреже.

Важан корак у развоју вишеслојних неуронских мрежа представља алгоритам повратног простирања грешке [21]. Овај алгоритам омогућава да се грешка израчуната на излазу мреже пренесе уназад кроз њене слојеве. На основу те грешке подешавају се тежине веза између неурона, чиме се мрежа постепено побољшава. Повратно простирање грешке учинило је обучавање вишеслојних мрежа практичнијим и омогућило им да уче сложеније односе између улазних података и излазних резултата.

Шира примјена дубоког учења постала је могућа тек када су се истовремено развили хардвер, методе обучавања и доступност података. Графичке процесорске јединице, могу паралелно да извршавају велики број сличних математичких операција. То их чини погодним за обучавање неуронских мрежа, које током рада захтијевају велики број операција над матрицама. Поред тога, дигитализација садржаја и развој интернет сервиса омогућили су формирање великих скупова података за обучавање и провјеру модела.

Једна од најпознатијих прекретница догодила се 2012. године, када је модел AlexNet остварио веома добре резултате у класификацији слика. Модел је користио дубоку конволуциону неуронску мрежу и био обучаван на великом скупу означених слика уз помоћ ГПУ рачунања. Његов успјех показао је да комбинација великог броја података, одговарајуће архитектуре и довољно снажног хардвера може значајно да побољша резултате у компјутерском виду. AlexNet је зато допринио широј прихваћености дубоког учења у истраживању и индустрији.

Даљи развој довео је до архитектуре трансформер, представљене 2017. године. За разлику од ранијих секвенцијалних модела, трансформер користи механизам пажње како би процијенио односе између различитих дијелова улазне секвенце. Овај приступ омогућава ефикаснију обраду дугих текстова и боље повезивање ријечи које су међусобно удаљене у реченици. Захваљујући томе, трансформер је постао основа за развој савремених језичких модела.

Развој од перцептрона до трансформера показује промјену у начину изградње система вјештачке интелигенције. Док су рани модели имали ограничену способност представљања сложених односа, савремене архитектуре могу да уче вишеслојне репрезентације из великих количина података.

3 Појам и границе вјештачке интелигенције

3.1 Проблем јединствене дефиниције

Вјештачка интелигенција нема једну дефиницију која обухвата све приступе, методе и системе развијене у овој области. Појам интелигенције може се повезати са опонашањем људског понашања, правилним закључивањем, учењем из искуства или успјешним остваривањем циља. Због тога избор дефиниције утиче на то који системи се класификују као вјештачка интелигенција.

Класични приступи разликују системе који мисле као људи и системе који дјелују као људи. Први приступ усмјерен је на опонашање људских когнитивних процеса, као што су учење, памћење и закључивање. Код другог приступа није пресудно како систем долази до резултата, већ да ли се његово понашање може упоредити са људским. Тјурингов тест представља најпознатији примјер таквог приступа, јер процјењује да ли човјек може да разликује машину од другог човјека током текстуалне комуникације [18], [27].

Друга два приступа полазе од рационалности. Системи који мисле рационално користе формална правила логике како би из познатих чињеница извели исправне закључке. Овај приступ био је посебно важан за развој симболичке AI. Системи који дјелују рационално бирају поступак који, на основу доступних информација, највише доприноси остваривању постављеног циља. Такво одређење погодније је за процјену савремених система, јер се њихова успјешност може мјерити према оствареним резултатима [18].

3.2 Однос AI, машинског учења и дубоког учења

Вјештачка интелигенција представља широку област и обухвата различите методе за изградњу система који могу да извршавају задатке повезане са људским способностима, као што су закључивање, учење, разумијевање језика и доношење одлука. Ова област обухвата и симболичке системе засноване на правилима и савремене моделе који уче из великих количина података.

Машинско учење је дио вјештачке интелигенције који се заснива на учењу образаца из података. Умјесто да се сва правила унапријед задају, модел се обучава на примјерима и подешава своје параметре на основу грешке у предвиђању. Машинско учење обухвата различите приступе, укључујући надгледано, ненадгледано и учење путем награђивања.

Дубоко учење представља ужи дио машинског учења. Оно користи вишеслојне неуронске мреже које могу да уче сложене репрезентације података. Дубљи слојеви мреже омогућавају постепену обраду информација, од једноставнијих особина до сложенијих образаца. Овакав приступ посебно је значајан у обради слика, говора и природног језика.

Генеративни модели су модели који, на основу научених образаца, стварају нови садржај. Тај садржај може бити текст, слика, звук или друга врста података. Иако се савремени генеративни модели углавном заснивају на дубоком учењу, није сваки модел дубоког учења генеративан. Постоје и дискриминативни модели који класификују улазне податке, односно, уочавају границу између класа улазних података. Разлика између генеративних и дискриминативних модела дакле зависи од циља обуке и врсте излаза који модел производи.

Овај однос може се представити као хијерархија: машинско учење је дио вјештачке интелигенције, дубоко учење је дио машинског учења, а онда генеративни модели

представљају посебну групу модела која се може заснивати на дубоком учењу [18].

3.3 AI систем, модел и апликација

Модел је математичка и рачунарска компонента која на основу улазних података даје одређени излаз. Он садржи параметре научене током обучавања, али сам по себи не мора обухватати податке, начин припреме улаза или кориснички интерфејс. У случају модела за класификацију текста, модел представља неуронску мрежу обучену за обраду текстуалних података и предвиђање припадајуће класе сентимента [18].

AI систем је шира цјелина која, поред модела, може обухватати скуп података, поступке чишћења и претпроцесирања, правила за обраду резултата, инфраструктуру и начин комуникације са корисником. На примјер, систем за анализу сентимента финансијских вијести може садржати учитавање вијести, претпроцесирање текста, извршавање предвиђања и приказ добијене класе.

Апликација представља практичну употребу једног или више AI система за остваривање конкретног циља. Апликација може бити програм, веб сервис или истраживачка скрипта која кориснику омогућава да унесе текст и добије процјену сентимента. У том случају класификациони модел је једна компонента, поступак обраде и предвиђања чини AI систем, а алат за анализу финансијских вијести представља апликацију.

Резултат читавог система не зависи само од његове архитектуре, већ и од података, претпроцесирања, начина обучавања модела и услова у којима се користи.

4 Класификација вјештачке интелигенције

4.1 Класификација према способностима

Подјела према способностима разликује системе према ширини и општости задатака које могу да извршавају [22].

4.1.1 Уска вјештачка интелигенција – ANI

Уска вјештачка интелигенција (ANI, од енгл. „Artificial Narrow Intelligence“) означава системе пројектоване за извршавање једног задатка или ограниченог скупа међусобно повезаних задатака. Такав систем може остварити веома добре резултате у јасно одређеном домену, али његово знање и способности нису општег карактера. Модел који је обучен за класификацију слика, на примјер, не може се без додатне обуке користити за разумијевање финансијских вијести. Ограничење није нужно последица слабих перформанси, већ чињенице да је систем оптимизован за одређени проблем и одређену врсту улазних података [18].

Већина данашњих практичних AI система припада овој категорији. Системи за препоруку процјењују које би производе, филмове или вијести корисник могао изабрати. Системи за препознавање слика класификују објекте или откривају одређене обрасце у визуелним подацима. Гласовни асистенти претварају говор у текст, препознају намјеру корисника и извршавају ограничене команде. Модели за анализу сентимента процјењују емоционалну или тржишну оријентацију текстуалног садржаја. Сви ови системи могу бити сложени и засновани на напредним алгоритмима, али су њихове способности и даље везане за конкретан задатак.

Важна особина ANI система јесте ограничена преносивост наученог знања. Модел може научити веома сложене правилности у скупу података, али то не значи да разумије те правилности на начин који би му омогућио поуздано ријешавање нових проблема.

Уска AI може бити веома корисна управо зато што је ограничена. Јасно дефинисан циљ омогућава избор одговарајућих података, метрике и услова тестирања.

4.1.2 Општа вјештачка интелигенција – AGI

Општа вјештачка интелигенција, односно AGI (Artificial General Intelligence), означава хипотетички тип система који би могао да учи, закључује и преноси знање између широког скупа различитих задатака. За разлику од уске AI, AGI не би био ограничен на један домен, већ би требало да се прилагођава новим проблемима без посебног пројектовања за сваки појединачни задатак. У идеализованом смислу, такав систем могао би да учи из искуства, планира, рјешава проблеме, разумије језик и примјењује раније стечено знање у новим ситуацијама [18].

Појам AGI није исто што и систем који извршава велики број унапријед одређених задатака. Широки интерфејс или могућност коришћења више алата не представљају сами по себи доказ опште интелигенције. За процјену AGI било би потребно размотрити способност система да поуздано рјешава нове проблеме, да учи са релативно мало података, да преноси знање између домена и да се прилагођава промјенљивим условима. Такви критеријуми су сложени, а међу истраживачима не постоји потпуна сагласност о томе како би се општа интелигенција мјерила.

AGI се зато може посматрати као истраживачки циљ и теоријска категорија, а не као јасно идентификован тип производа. Савремени велики језички модели показују изу-

зетну ширину у обради различитих задатака, али њихова успјешност може значајно зависити од формулације упита, доступности контекста, квалитета података и додатних компоненти система. Способност генерисања увјерљивог текста не значи аутоматски да систем посједује стабилан модел свијета, поуздано расуђивање или општу способност учења.

AGI се често јавља као блиска или већ остварена технологија, али не постоји општеприхваћен критеријум на основу којег би се могло закључити да је такав систем развијен. Због тога се у овој класификацији AGI наводи као концепт који показује границу између данашњих специјализованих система и замишљеног система широке интелигенције.

4.1.3 Суперинтелигенција – ASI

Суперинтелигенција, односно ASI (Artificial Superintelligence), представља још шири и апстрактнији концепт. Њиме се означава хипотетички систем који би у великом броју когнитивних области надмашивао људске способности. То би могло укључивати учење, научно закључивање, планирање, језичку комуникацију, креативно рјешавање проблема и доношење одлука. За разлику од AGI, који се односи на широк распон задатака, ASI подразумијева надмашивање људи у релевантним интелектуалним задацима [18].

ASI није постојећа техничка категорија коју је могуће анализирати на исти начин као класификатор, неуронску мрежу или експертни систем. Не постоји стандардизован модел суперинтелигенције нити скуп емпиријских тестова који би омогућили њено непосредно мјерење. Због тога се ASI углавном разматра у оквиру филозофије технологије, предвиђања будућег развоја, безбједности AI система и етике. У тим расправама пажња се усмјерава на могуће посљедице система који би имао широке способности и могао самостално да унапређује своје методе или утиче на комплексна окружења.

Приликом обраде ASI треба избјећи изједначавање са савременим моделима који показују високе резултате на појединачним тестовима. Надмашивање човјека у шаху, препознавању објеката или генерисању текста представља успјех у конкретном задатку, али није доказ суперинтелигенције. ASI подразумијева широку и стабилну надмоћ кроз велики број различитих когнитивних способности, што за сада остаје теоријска претпоставка.

4.1.4 Ограничења ове подјеле

Подјела на ANI, AGI и ASI корисна је за објашњење различитих нивоа општости, али има важна ограничења. Прво, граница подјеле није прецизно одређена, а AGI и ASI су хипотетички концепти без општеприхваћених мјерила [18].

Друго, ова подјела мијеша постојеће системе са хипотетичким развојним стадијумима. ANI се односи на реалне и широко распрострањене системе, док су AGI и ASI концепти чије остварење и критеријуми процјене нису општеприхваћени. Због тога категорије не треба тумачити као прецизну временску линију развоја. Оне више служе као концептуални оквир за разликовање специјализованих система од општих и хипотетичких способности.

Треће, ниво способности не говори ништа довољно прецизно о начину на који је систем направљен. Два система могу бити уска AI, а да један буде симболички експертни систем, док други користи дубоку неуронску мрежу. Обрнуто, исти технички приступ може бити употребљен у различитим апликацијама и за различите нивое аутономије. Зато класификацију према способностима треба комбиновати са класификацијама према техничком приступу, сврси, улози и начину имплементације.

На крају, термин „интелигенција“ у овој подјели може довести до различитих тумачења. Високе перформансе на тесту или способност производње увјерљивог одговора не доказују свијест, разумијевање или људски начин мишљења. Прецизнији опис увијек треба да наведе задатак, податке, метрику и услове у којима је систем процијењен.

4.2 Класификација према техникама и начинима учења

Класификација према техникама и начинима учења посматра начин на који је систем вјештачке интелигенције изграђен и на који долази до својих резултата. Питање није само шта систем може да уради, већ којим поступком учи, закључује или оптимизује резултат [18].

Развој вјештачке интелигенције може се посматрати и као историјско помјерање тежишта. Рани системи ослањали су се на знање које су стручњаци и програмери унапријед записивали у облику правила. Каснији системи почели су да изводе правилности из примјера, док савремени модели комбинују велике скупове података, сложене архитектуре и различите поступке оптимизације. Ниједан од ових приступа није универзално најбољи. Избор технике зависи од врсте података, циља система, доступности ознака, захтјева за објашњивошћу, ограничења рачунарских ресурса и посљедица могуће грешке.

4.2.1 Симболичка вјештачка интелигенција

Симболичка вјештачка интелигенција заснива се на претпоставци да се знање може представити помоћу симбола, појмова, односа и правила, а да се закључивање може описати формалним поступком. У таквом систему улазни подаци најприје се превode у структурисану репрезентацију, након чега механизам закључивања примјењује дефинисана правила и изводи закључак. Систем, дакле, не мора да учи статистичке обрасце из великог броја примјера већ његово понашање првенствено произлази из знања и поступка који су уграђени у програм [16], [18].

Основни елементи симболичког система могу бити чињенице, логички искази, правила таутолошких принципа, семантичке мреже и процедуре за претраживање простора могућих рјешења. Формална логика омогућава да се односи између појмова прецизно запишу, док механизам закључивања одређује којим редослиједом ће се правила примјенити. У проблемима планирања и рјешавања загонетки систем може претраживати различите путеве ка циљу, одбацити недозвољена стања и бирати рјешење према унапријед дефинисаном критеријуму. На тај начин интелигентно понашање настаје комбинацијом репрезентације знања и контролисаног закључивања.

Најпознатији историјски облик примјене симболичке AI јесу експертни системи. Како је и раније наведено, они су покушавали да знање стручњака из одређене области пренесу у рачунарски програм. Типичан експертни систем састојао се од базе знања, радне меморије са чињеницама о конкретном случају и инференцијалног механизма. Поред тога, могао је садржати и компоненту за објашњавање, која кориснику приказује која су правила примијењена и како је изведен закључак.

Најважнија предност симболичког приступа јесте да када су правила јасно записана, могуће је провјерити конзистентност и објаснити због чега је одређени закључак изведен. То је нарочито важно у областима у којима одлука мора бити образложена или усклађена са прописима. Симболички системи могу бити корисни и када је доступно мало података, али постоји поуздано стручно знање које се може формализовати. Ограничења постају видљива када се систем сусретне са неструктурираним, непотпуним или промјен-

љивим подацима. Због тога симболичка AI данас најчешће постоји као самостални приступ у јасно дефинисаним доменима или као дио хибридних система.

4.2.2 Машинско учење

Машинско учење обухвата методе у којима се параметри модела подешавају на основу података. Циљ је да модел научене обрасце примијени на нове примјере. Поједини начини учења разликују се према томе да ли модел добија очекивани одговор, самостално проналази структуру података или учи кроз интеракцију са окружењем [18].

Код надгледаног учења сваки примјер има улаз и познату ознаку или циљну вриједност. Модел учи функцију која повезује улаз са тим циљем. У класификацији је излаз дискретна класа, као што су позитиван, негативан или неутралан сентимент, док је у регресији излаз нумеричка вриједност. Линеарна регресија, стабла одлучивања, SVM и случајне шуме представљају типичне моделе овог начина учења. Класификација сентимента у практичном дијелу рада припада надгледаном учењу, јер свака вијест има унапријед дефинисану ознаку.

Код ненадгледаног учења модел не добија унапријед дефинисане ознаке, већ покушава да пронађе правилности које постоје у самим подацима. На основу сличности између примјера може формирати групе, издвојити неуобичајене случајеве или приказати податке кроз мањи број важних особина. Овакав приступ је користан у почетној анализи скупа података и откривању образаца, али пронађене групе немају унапријед дато значење, па их је потребно додатно протумачити у односу на конкретан проблем.

Полунадгледано учење комбинује мањи број означених са већим бројем неозначених примјера.

Самонадгледано учење конструише помоћни задатак из самих података, на примјер предвиђање сакривеног дијела текста. Ове методе су корисне када је означавање скупо, а доступна је велика количина неозначених података.

Учење путем награђивања заснива се на интеракцији агента са окружењем. Агент бира акције и добија награде или казне, са циљем да максимизује укупну награду током времена. Примјењује се у играма, роботизи, управљању и истраживању стратегија управљања портфолиом.

Квалитет машинског учења зависи у многоме од квалитета података, поузданости ознака, правилне подјеле скупа и избора метрике. Висок резултат на тесту не гарантује успјех у реалној примјени, па је потребно анализирати грешке и ограничења модела.

4.2.3 Неуронске мреже и дубоко учење

Неуронске мреже су модели састављени од међусобно повезаних рачунских јединица. Свака јединица комбинује улазе помоћу тежина и активационе функције, а више слојева омогућава учење сложенијих репрезентација. Перцептрон је рани примјер неуронског модела за класификацију, док вишеслојне мреже могу представљати нелинеарне односе у подацима [20].

Током обучавања функција губитка мјери разлику између предикције и очекиваног резултата. Повратно простирање грешке користи ту разлику за израчунавање промјена тежина, а градијентни метод постепено ажурира параметре мреже. Успјех зависи од архитектуре, података, функције губитка и оптимизационог поступка.

Конволуционе мреже користе локалне обрасце и посебно су погодне за слике. AlexNet је показао да комбинација дубоке архитектуре, великог скупа података и ГПУ рачунања може значајно побољшати класификацију слика [11]. Рекурентне мреже обрађују

секвенце користећи стање из претходних корака, али је таква обрада тежа за паралелизацију. ResNet је увео резидуалне везе између слојева и тиме олакшао тренирање веома дубоких мрежа [8].

Израз „дубоко“ у дубоком учењу односи се на број и организацију слојева репрезентације. Он не означава виши ниво свијести, самосталности или опште интелигенције. Дубока мрежа може постићи одличне резултате на прецизно дефинисаном задатку, а да истовремено нема способност да исти начин рада пренесе на неповезану област.

4.2.4 Обрада природног језика и трансформер модели

Обрада природног језика (Natural Language Processing, NLP) обухвата методе за анализу и обраду људског језика. Она је област примјене AI, а не засебан начин учења: NLP системи могу користити симболичка правила, статистичко машинско учење или дубоке неуронске мреже. Развој ове области кретао се од ручно дефинисаних правила и статистичких модела према неуронским мрежама и дистрибуираним репрезентацијама ријечи.

Трансформер архитектура користи механизам пажње, који моделу омогућава да процјењује односе између различитих дијелова текстуалне секвенце [28]. Код механизма само-пажње сваки елемент секвенце може узети у обзир остале елементе и одредити који су му најважнији за тумачење. На тај начин модел може повезати ријечи које су међусобно удаљене и боље обрадити значење реченице у цјелини. За разлику од строго секвенцијалне обраде, трансформер омогућава ефикаснију паралелизацију током учења.

Пошто сама пажња не садржи информацију о редослиједу елемената, трансформер користи позиционе информације. Оне омогућавају моделу да разликује почетак, средину и крај секвенце, као и односе између ријечи према њиховом положају.

Према организацији компоненти, разликују се енкодерски модели за обраду и класификацију улаза, декодерски модели за генерисање секвенце и енцоде-р-декодер модели који улаз претварају у нови излаз, као код превођења. Оваква флексибилност омогућила је примјену трансформер-а у класификацији, превођењу, сажимању, одговарању на питања и генерисању текста. Његово ограничење је што обрада дугих секвенци може захтијевати много меморије и рачунања, нарочито када сваки елемент обраћа пажњу на велики број других елемената.

Енкодерски трансформер модели углавном се користе за разумијевање и класификацију текста, док ауторегресивни модели предвиђају наредни токен и усмјерени су на генерисање. Због тога се NLP модели могу разликовати према архитектури, начину обуке, домену и конкретном задатку. Трансформер се зато не може свести на једну конкретну примјену, већ представља општу архитектуру која се прилагођава различитим задацима обраде језика.

4.2.5 Генеративни модели према врсти излаза

Генеративна вјештачка интелигенција обухвата системе који уче обрасце у подацима и на основу њих стварају нове излазе, као што су текст, слике, звук или програмски код. За разлику од дискриминативног модела, који улаз сврстава у унапријед дефинисану класу, генеративни модел покушава да научи структуру података како би произвео нови примјер. Због тога се генеративна AI класификује према врсти задатка и резултата, а не према једној конкретној архитектури [29], [30].

Начин генерисања зависи од примијењеног модела. Постоје аутоенкодери, који уче компактну унутрашњу репрезентацију података и користе је за њихову реконструкци-

ју или стварање сличних примјера. Затим ГАН модели, који генеришу садржај кроз надметање генератора и дискриминатора, док дифузиони модели постепено уклањају шум из почетне случајне репрезентације. Велики језички модели стварају текст тако што предвиђају наредни токен на основу претходног контекста. Иако се сви ови приступи разликују, заједничко им је да не дају само ознаку постојећем улазу, већ производе нови излаз.

Генеративни системи могу бити корисни за писање, сажимање, превођење и стварање различитих врста садржаја. Ипак, увјерљив и граматички исправан излаз није гаранција његове тачности. Модел може произвести нетачан или непровјерен садржај, што је посебно важно у финансијским и другим осјетљивим областима. Зато њихова практична употреба захтијева провјеру извора, јасно дефинисан домен и одговарајући људски надзор.

4.2.6 Еволутивни алгоритми и рачунарска интелигенција

Еволутивни алгоритми заснивају се на идеји претраживања простора рјешења кроз такозвану популацију кандидата. Сваком кандидату додјељује се вриједност функције прилагођености циљу, након чега се успјешнији кандидати бирају, комбинују и мијењају. У генетским алгоритмима комбиновање се често описује укрштањем, док случајне промјене представљају мутацију. Понављањем ових корака популација може да се помјера ка рјешењима која боље задовољавају дефинисани циљ [18].

За разлику од градијентног учења, еволутивна оптимизација не захтијева да функција циља буде диференцијабилна. То омогућава примјену у проблемима са дискретним одлукама, сложеним ограничењима или скупом правила који није једноставно изразити глатком функцијом. Еволутивне стратегије могу оптимизовати нумеричке параметре, док генетски алгоритми могу претраживати и комбинације дискретних елемената. Ипак, овакве методе често захтијевају велики број процјена кандидата и могу бити рачунски скупе.

Примјене укључују распоређивање, планирање рута, избор портфолија, оптимизацију производних процеса и аутоматско проналажење архитектура неуронских мрежа. У потоњем случају еволутивни поступак може бирати број слојева, типове операција или везе између компоненти, док се квалитет архитектуре процјењује на валидационом задатку. Овај приступ не треба мијешати са биолошким учењем: ријеч је о рачунској оптимизацији инспирисаној еволутивним принципима.

Рачунарска интелигенција обухвата шири скуп метода које се често повезују са неуронским мрежама, фази системима и еволутивним алгоритмима. Заједничко им је настојање да се ријеше проблеми у којима су подаци непрецизни, простор рјешења велик или класично симболичко програмирање непрактично. У савременим системима еволутивни алгоритам може, на примјер, оптимизовати хиперпараметре неуронске мреже, док сама мрежа учи градијентним методама. Таква комбинација додатно показује да техничке категорије нису увијек изоловане.

4.2.7 Фази системи

Фази системи користе фази логику за описивање ситуација у којима границе између категорија нису потпуно јасне [32]. У класичној логици тврдња је тачна или нетачна, док фази логика омогућава да одређени објекат припада неком скупу у различитом степеноу. На примјер, температура од 28 °C може бити дјелимично „висока“, без потребе да се одреди оштра граница између високе и ниске температуре.

Фази систем ову идеју примјењује кроз функције припадности и скуп правила. Улазна вриједност се најприје претвара у опис као што су „ниско“, „средње“ или „високо“. Затим се примјењују правила облика: „ако је температура висока, смањи гријање“. На крају се добијени фази резултат претвара у конкретну излазну вриједност. На овај начин систем може користити непрецизне изразе, али их и даље обрађује формално и математички.

Овакви системи користе се у управљању, одлучивању и ситуацијама у којима је тешко поставити строге прагове. Фази логика није исто што и вјероватноћа: степен припадности показује колико нека вриједност одговара одређеном појму, док вјероватноћа описује могућност да се неки догађај догоди.

Фази системи могу се комбиновати са неуронским мрежама у неуро-фази моделима. Неуронска мрежа тада учи параметре из података, док фази правила омогућавају разумљивији облик одлучивања. Ипак, велики број правила може учинити систем сложеним, па фази приступ не гарантује аутоматски потпуну објашњивост.

4.2.8 Хибридна и неуро-симболичка AI

Хибридна вјештачка интелигенција повезује двије или више техника у један систем како би искористила њихове различите предности. На примјер, неуронски модел може учити обрасце из података без јасне структуре, док симболичка компонента примјењује правила и ограничења. Хибридна се зато не односи на једну посебну архитектуру, већ на начин организовања више компоненти [16], [18].

Неуро-симболичка AI представља важан облик хибридног приступа. Неуронска компонента може из текста, слике или звука издвојити релевантне обрасце, док симболичка компонента користи те информације за провјеру односа и доношење закључака. У систему за анализу финансијских докумената, неуронски дио може препознати ентитете и догађаје, а симболички дио провјерити да ли су они повезани у складу са дефинисаним правилима.

Овакво повезивање покушава да споји прилагодљивост неуронских модела са експлицитношћу симболичких система. Неуронски модели добро обрађују велике и неструктурисане скупове података, али њихове одлуке могу бити тешке за објашњење. Симболичка правила се лакше провјеравају, али су осјетљивија на непотпуно знање и промјене у домену.

Хибридни системи ипак имају и ограничења. Потребно је ускладити њихове разлике, а грешка у једној компоненти може утицати на цијели систем. Због већег броја компоненти развој и одржавање могу бити сложенији. Хибридни приступ је начин да се техничке предности различитих метода пажљиво комбинују.

4.2.9 Поређење техничких приступа

Технички приступи разликују се по многим основама. Симболички системи користе задата правила и лакше образлажу одлуке, али се теже прилагођавају промјенама. Машинско учење и дубоке неуронске мреже обрасце изводе из података и могу представити сложене односе, али обично захтијевају више података и рачунарских ресурса. Генеративни модели стварају нове излазе, еволутивни алгоритми претражују простор могућих рјешења, а фази системи обрађују непрецизне појмове кроз степене припадности [18], [22].

Не постоји техника која је најбоља за све проблеме. Симболичка правила могу бити прикладна за јасно дефинисане процедуре, дубоко учење за слике и велике текстуалне скупове, еволутивни алгоритми за сложену оптимизацију, а фази системи за управљање

и одлучивање са постепеним вриједностима. У пракси се често комбинује више приступа, при чему се избор заснива на тачности, робусности, објашњивости, трошку и ризику.

4.3 Класификација према улози у одлучивању и степену аутономије

Улога система у одлучивању и степен аутономије одређују да ли AI пружа подршку човјеку или самостално извршава радње [22].

4.3.1 Асистивни системи

Асистивни системи имају сврху да подрже човјека у анализи, процјени или доношењу одлука. Они могу обрађивати податке, давати препоруке, упозоравати на могуће проблеме или предлагати више опција, али корисник задржава контролу над коначном одлуком. Овакав приступ је користан када је потребна брзина обраде велике количине података, а истовремено је важно да стручњак може провјерити резултат и преузети одговорност [22], [23].

Примјери укључују системе за подршку љекарима, алате за процјену кредитног ризика и моделе за анализу финансијских података. Асистивни систем не мора бити једноставан нити мање способан од аутономног система. Његова кључна особина је да резултат служи као помоћ човјеку, а не као аутоматска наредба.

4.3.2 Аутономни системи

Аутономни системи могу самостално извршавати низ радњи у одређеном окружењу, од опажања ситуације до избора и спровођења акције. За разлику од асистивног система, аутономни систем не даје само препоруку, већ може директно дјеловати без претходног одобрења за сваки појединачни корак. Примјери су аутономна возила, индустријски роботи, системи за аутоматско трговање и софтверски агенти [22], [24].

Аутономија је увијек ограничена условима за које је систем пројектован. Систем може самостално радити у познатом и контролисаном окружењу, али захтијевати људску интервенцију када наиђе на непредвиђену ситуацију. Због тога се при процјени аутономног система морају узети у обзир поузданост модела, посљедице грешке и начин преузимања контроле.

4.3.3 Степен аутономије

Асистивни и аутономни системи нису увијек двије потпуно одвојене категорије, већ представљају крајеве спектра људског учешћа. На једном крају систем само приказује податке или даје препоруку. На средини може аутоматски извршити рутинске кораке, али тражити потврду за важније одлуке. На другом крају може самостално опажати окружење, доносити одлуке и извршавати радње [22].

Степен аутономије зато није трајна особина самог модела. Исти модел може бити коришћен као алат за подршку стручњаку или као дио аутоматизованог система, у зависности од правила, радног окружења и овлашћења која му се дају. Из безбиједносних разлога стога мора постојати прецизан опис шта систем ради самостално, гдје је потребан људски надзор и ко доноси коју коначну одлуку.

4.4 Класификација према окружењу имплементације

Овај критеријум описује гдје се извршава модел, а не његову архитектуру или сврху. Извршавање у рачунарском облаку и на рубним уређајима представља шире организационе обрасце, док је уграђена вјештачка интелигенција специфичан облик извршавања на рубном уређају, при којем је модел интегрисан у намјенски уређај или контролни систем [24].

4.4.1 Извршавање у рачунарском облаку

Извршавање у рачунарском облаку означава системе код којих се обрада података и извршавање модела обављају на удаљеним серверима, а корисник им приступа путем мреже. Овакво окружење омогућава коришћење велике рачунарске снаге и складишта података без потребе да се сва инфраструктура налази код корисника. Модели се могу централизовано ажурирати, а ресурси се прилагођавају оптерећењу [24].

Недостаци приступа заснованог на рачунарском облаку су зависност од мрежне везе, могуће кашњење и потреба да се подаци шаљу на удаљени сервер. Због тога се морају размотрити приватност, безбједност и начин контроле података, нарочито када систем обрађује осјетљиве информације.

4.4.2 Извршавање на рубним уређајима

Извршавање на рубним уређајима подразумијева извршавање модела близу мјеста на којем подаци настају, на примјер на телефону, камери, сензору или локалном рачунару. Обрада се може извршити без слања сваког податка у рачунарску облак, што смањује кашњење и може побољшати приватност. Овај приступ је користан када систем мора брзо реаговати или када мрежна веза није стално доступна [24].

Локални уређаји обично имају мање меморије, слабији процесор и ограничену потрошњу енергије. Због тога се модели често морају посебно прилагодити хардверу на којем ће радити.

4.4.3 Уграђена вјештачка интелигенција

Уграђена вјештачка интелигенција представља ужи случај извршавања на рубном уређају, у којем је модел уграђен директно у уређај или контролни систем. Такви системи могу бити дио сензора, индустријских уређаја, аутомобила, кућних апарата и других производа. Модел ради као дио шире функције уређаја, често без видљивог корисничког интерфејса [24].

Код уграђених система посебно су важни мала потрошња енергије, поузданост, ограничена меморија и рад у реалном времену. Ажурирање модела може бити теже него у рачунарском облаку, па се избор архитектуре и провјера рада морају обавити прије уградње у уређај.

5 Повезивање критеријума у вишедимензионалну подјелу

Једна ознака најчешће не описује AI систем довољно прецизно. Тврдња да је систем заснован на дубоком учењу говори само о његовој техници, али не објашњава које задатке обавља, колико је аутономан, чему служи нити гдје се извршава. Потпунији опис добија се комбиновањем више критеријума: способности, технике, сврхе, аутономије и радног окружења [22].

Примјена овог оквира може се показати на општем примјеру језичког модела за класификацију сентимента. Такав модел припада уској вјештачкој интелигенцији јер извршава јасно ограничен задатак. Технички може бити заснован на дубокој неуронској мрежи и додатно обучен надгледаним учењем на означеним текстовима. Према врсти излаза, ријеч је о дискриминативном класификатору који улазни текст сврстава у унапријед дефинисане класе, без генерисања новог садржаја.

Исти модел може бити дио асистивног система, у којем аналитичар провјерава резултат, или дио дјелимично аутоматизованог система, у којем се резултат просљеђује наредној компоненти. Његова улога и степен аутономије зато не произлазе само из архитектуре модела, већ и из начина на који је уграђен у шири систем. Модел се може извршавати у рачунарском облаку или локалном окружењу, у зависности од инфраструктуре у коју је укључен.

Овакав приступ је важан јер системи са сличном техничком основом могу имати различиту намјену. MYCIN је уска и углавном асистивна AI заснована на симболичким правилима, чија је сврха подршка стручњаку. Систем аутономне вожње има сложенију функцију јер комбинује опажање, предвиђање и планирање, а ниво његове аутономије зависи од улоге људског надзора. Велики језички модел може подржавати више задатака, као што су генерисање, сажимање и анализа текста, али његова класификација зависи од начина на који је укључен у конкретан систем.

Категорије се могу преклапати и нису увијек трајна својства модела. Исти модел може бити коришћен као асистивни алат који даје препоруке или као дио аутоматизованог система који самостално покреће одређене радње. Такође, модел који се извршава у рачунарском облаку може се, након смањења и прилагођавања, покренути на локалном уређају. Због тога при класификацији треба разликовати сам модел од система у којем се користи и описати конкретне услове његове примјене.

Табела 1. Вишедимензионална класификација система примијењеног у практичном дијелу

Критеријум	Класификација система	Образложење
Способност	Уска вјештачка интелигенција	Систем обавља ограничен задатак класификације вијести у три класе.
Техника учења	Дубоко учење; надгледана додатна обука	FinBERT је трансформерски модел чији се параметри додатно обучавају на означеним примјерима.
Врста излаза	Дискриминативна класификација	Систем додјељује једну од ознака bullish, bearish или neutral.
Улога у одлучивању	Асистивна	Резултат служи анализи и не покреће самостално трговање нити другу финансијску радњу.
Степен аутономије	Низак	Човјек бира податке, покреће обраду и тумачи резултат.
Окружење извршавања	Рачунарски облак током обуке	Обука је извршена у Google Colab окружењу; модел се може покренути и локално.

Вишедимензионални приступ зато омогућава прецизнији опис AI система. При њиховој анализи потребно је узети у обзир не само начин на који су изграђени, већ и податке које користе, задатак који обављају, могућност људског надзора, ограничења и услове примјене. Овакав оквир представља основу за наставак рада, у којем ће се општи теоријски преглед повезати са примјеном вјештачке интелигенције у финансијама.

6 Практични дио рада

6.1 Анализа финансијског сентимента (Financial Sentiment Analysis — FSA)

Финансијска анализа сентимента представља специјализовану примјену обраде природног језика, са методама и изазовима који зависе од финансијског домена [5], [6].

6.1.1 Увод и дефиниција

Анализа финансијског сентимента (ФСА) представља примјену обраде природног језика (НЛП) на финансијске текстове, укључујући вијести, извјештаје компанија, објаве на друштвеним мрежама, позиве о пословним резултатима и регулаторне извјештаје. Задатак може обухватити класификацију текста као позитивног, негативног или неутралног, процјену интензитета сентимента и повезивање текстуалног сигнала са тржишним показатељима [6].

Финансијски језик је доменски специфичан. Енглески појмови као *liability*, *default*, *exposure* и *short* имају значења која се не могу поуздано извести из општих ријечника сентимента. Контекст је зато пресудан: реченица „Компанија је смањила губитке за 30%“ садржи негативну ријеч, али преноси повољну информацију. Финансијски текстови такође комбинују бројчане и описне податке, а временска вриједност информације може брзо опадати.

Могу се разликовати три повезана, али различита нивоа сентимента у финансијском контексту:

- Текстуални сентимент — оно што текст експлицитно или имплицитно изражава (домен НЛП-а)
- Сентимент инвеститора — субјективни ставови и очекивања појединачних или институционалних инвеститора (домен бихевиоралне финансије)
- Тржишни сентимент — агрегатно расположење тржишта које се манифестује кроз цијене, обиме и волатилност (домен квантитативних финансија)

ФСА се примарно бави првим нивоом — екстракцијом сентимента из текста — али његова вриједност лежи у способности да информише па и предвиди друга два нивоа. Управо та веза чини ФСА важном истраживачком области на пресеку НЛП-а и финансија [5].

6.1.2 Еволуција техника — од рјечника до великих језичких модела

1 Лексиконски приступ (2004–2014) Прве систематске методе ФСА ослањале су се на ручно креиране рјечнике (лексиконе) који приписују сентимент појединачним ријечима или фразама. Кључни допринос у овом периоду дали су Лугран и МекДоналд [12] који су демонстрирали да општи ријечници сентимента дају погрешне резултате на финансијским текстовима. Њихов рад, објављен у часопису „The Journal of Finance“, анализирао је преко 50.000 годишњих извјештаја и показао да готово три четвртине ријечи класификованих као „негативне“ у општим рјечницима заправо немају негативно значење у финансијском контексту. На основу тога, креирали су специјализовани финансијски лексикон који и данас служи као основа за процјену напреднијих метода. Предности лексиконског приступа су транспарентност и једноставност имплементације. Недостаци су фундаментални: немогућност разумијевања контекста, негација („није лоше“ се третира као

негативно због ријечи "лоше"), сарказма и сложених синтаксичких структура. Лексикони третирају сваку ријеч изоловано, игноришући односе међу ријечима у реченици [12].

2 Машинско учење (2011–2018) Примјена класичних алгоритама машинског учења омогућила је да се обрасци уче из означених података, умјесто да се анализа ослања искључиво на унапријед дефинисане листе ријечи. Текст се најчешће представљао нумерички, на примјер учесталост ријечи и TF-IDF обиљежјима, а затим класификовао моделима као што су логистичка регресија и машина потпорних вектора. Кључно ограничење био је недостатак означених података у финансијском домену. "Financial PhraseBank" садржи 4846 реченице из финансијских вијести, које су означили испитаници са финансијским знањем, и постао је често коришћен референтни скуп за процјену модела финансијског сентимента [13].

3 Дубоко учење (2015–2019) Увођење дубоких неуронских мрежа омогућило је аутоматско учење сложенијих репрезентација текста. Рекурентне архитектуре, укључујући LSTM, намијењене су обради секвенци и ублажавању проблема учења дугорочних зависности [10]. Механизам пажње омогућио је моделу да различито посматра дијелове улазне секвенце, а првобитно је развијен у контексту неуронског машинског превођења [2]. На примјер, у реченици „Упркос паду прихода у трећем кварталу, компанија је значајно побољшала оперативне марже“, модел може научити да је дио „побољшала оперативне марже“ нарочито важан за одређивање сентимента.

4 Претходно тренирани језички модели — FinBERT ера (2018–2023) Кључни преломни тренутак за ФСА био је развој претходно обучених језичких модела, посебно BERT-а. Умјесто обуке од почетка на малом финансијском скупу, полази се од модела који је опште језичко знање стекао на великом корпусу, а затим се додатно обучава на мањем означеном скупу за конкретан задатак [4].

Арачи је представио FinBERT [1], варијанту BERT-а додатно претходно обучену на корпусу Ројтерсових финансијских вијести. Резултати његовог рада указују да доменско прилагођавање може побољшати класификацију финансијског сентимента и када је означени скуп релативно мали. Преглед Ду и др. (2024) такође показује да су модели засновани на BERT-у снажне методе за класификацију финансијског сентимента, али се пријављени резултати морају тумачити у оквиру конкретног скупа и начина подјеле података.

5 Велики језички модели — LLM ера (2023–данас) Појава великих језичких модела проширила је могућности FSA на рад без додатне обуке, учење из малог броја примјера, сажимање и одговарање на питања. BloombergGPT је модел са 50 милијарди параметара, обучен на 363 милијарде токена финансијских података и додатних 345 милијарди токена општих података [29]. FinGPT је предложен као опенсорс фрејмворк за прилагођавање великих језичких модела финансијским задацима уз параметарски ефикасне поступке обуке [30]. Ипак, резултати зависе од скупа података, формулације упита, избора модела и начина процјене, па се предност великих језичких модела не може претпоставити за сваки задатак класификације финансијског сентимента [5].

6.1.3 Примјене FSA у финансијском сектору

Примјери примјене сентименталних и других финансијских текстуалних сигнала обухватају [6]:

- **Предвиђање цијена и прихода.** Сентимент из вијести и других текстуалних извора користи се као додатни индикатор уз историјске тржишне податке.
- **Предвиђање волатилности.** Текстуални сигнал може бити један од улаза у моделе управљања ризиком и процјене будуће нестабилности.
- **Анализа позива о пословним резултатима.** Посматрају се тон и формулације којима руководство описује резултате и очекивања.

6.1.4 Закључак и будући правци примјене вјештачке интелигенције за FSA

ФСА се развила од лексиконског бројања позитивних и негативних ријечи до модела који контекстуално представљају финансијски језик. Специјализовани модели као што је FinBERT показују значај доменског прилагођавања [1], [31]. Велики финансијски језички модели, међу којима су BloombergGPT и FinGPT, проширују могућности на генерисање, сажимање и сложеније анализе, али истовремено отварају питања трошка, поновљивости и контроле резултата [29]. Због тога избор модела зависи од конкретног задатка: за класификацију са јасно дефинисаним ознакама мањи специјализовани модел може бити практичнији, док су већи модели погоднији када је потребна шира контекстуална обрада. Даљи развој FSA обухвата мултимодалну анализу текста, табела и графикана, вишејезичке моделе, обраду токова вијести у реалном времену и методе објашњиве вјештачке интелигенције.

6.2 Теоријска основа

Теоријски дио описује трансформерску основу модела, финансијско доменско прилагођавање и поступак додатне обуке [4], [28].

6.2.1 BERT и трансформерска архитектура

BERT је језички модел заснован на трансформер архитектури. За разлику од приступа који текст обрађују искључиво слијева надесно, BERT током предобуке користи контекст са обје стране посматраног токена. Таква репрезентација омогућава моделу да иста ријеч добије различито значење у зависности од реченице у којој се појављује [4], [28].

Улазни текст се прво разлаже на мање јединице које модел може да обради. BERT затим посматра ријечи у њиховом ширем контексту и учи односе између њих. На крају се научена репрезентација текста користи за одређивање припадајуће класе сентимента.

6.2.2 FinBERT

FinBERT представља прилагођавање BERT модела финансијском домену. Модел ProsusAI/finbert [19] препознаје три ознаке: positive, negative и neutral. Његова предност је познавање финансијске терминологије, али то не значи да је унапријед прилагођен свим поддоменима финансија.

Крипто вијести садрже изразе који се рјеђе појављују у традиционалним финансијским корпусима, као што су назив мреже, токена, протокола и техничких надоградњи. Због тога се очекује доменски помак између података на којима је FinBERT првобитно обучен и Ethereum вијести коришћених у овом пројекту. Додатна обука треба да прилагоди постојеће репрезентације специфичним језичким и тржишним обрасцима тог домена.

6.2.3 Додатна обука модела

Додатна обука, односно фине-тјунинг, полази од већ научених параметара модела. Умијесто обуке неуронске мреже од почетка, модел се наставља обучавати на мањем означеном скупу података за конкретан задатак. Овај приступ је погодан када је доступна ограничена количина означеног текста, као у случају издвојеног Ethereum подскупа [4].

У пројекту је спроведена пуна додатна обука модела, без LoRA или других метода ефикасног прилагођавања параметара. FinBERT је довољно мали да се таква обука изврши на NVIDIA Tesla T4 ГПУ-у са расположивом меморијом, а цјелокупан тренинг од три епохе трајао је око четири минута.

6.3 Циљ и истраживачко питање

Циљ пројекта је да се утврди да ли се претходно обучени модел ProsusAI/finbert може побољшати додатном обуком на вијестима повезаним са Ethereum-ом. Моделу се додјељује једна од три циљне ознаке: *bullish*, *bearish* или *neutral*. Ознаке су изведене из корисничких гласова на платформи CryptoPanic и представљају перципирани тржишни правац вијести.

Истраживачко питање гласи:

> Да ли додатна обука FinBERT модела на Ethereum вијестима побољшава класификацију циљних ознака у односу на оригинални FinBERT, и да ли се побољшање задржава при временској подјели података?

У раду се јасно разликују текстуални сентимент и тржишни правац. Оригинални FinBERT предвиђа текстуални сентимент са ознакама *positive*, *negative* и *neutral*, док циљни скуп користи ознаке *bullish*, *bearish* и *neutral*, изведене из гласова корисника. Мапирање класа је технички усклађено ради тренирања и поређења, али та два појма нису потпуно семантички једнака. Због тога се резултати тумаче као класификација ознака перципираног тржишног правца, а не као директно мјерење текстуалног сентимента.

6.4 Скуп података и припрема

Коришћен је скуп ExponentialScience/DLT-Sentiment-News, који садржи 23.301 вијест и обухвата период од јануара 2021. до маја 2025. године. Скуп је дио колекције DLT-Corpus [9]. Странице скупа приступљено је 7. септембра 2026. године, а наведена лиценца је CC BY-NC 4.0 [7].

Вијести и агрегирани гласови корисника преузети су са платформе CryptoPanic. Према документацији скупа, чланци са недовољним бројем гласова искључени су прагом заснованим на медијани, гласови су нормализовани према укупном ангажману, а 25. и 75. перцентил коришћени су као границе за додјелу негативне, неутралне и позитивне категорије у свакој димензији. Ознака *market_direction* зато представља агрегирану процјену заједнице, а не независну стручну анотацију текста.

Из скупа су издвојене вијести које у наслову, опису или тексту садрже термине *ethereum*, *ether* или *eth*. Након уклањања празних записа и идентичних текстуалних дупликата добијен је Ethereum подскуп од 4.721 примјера. Мали број гласова, самоселекција корисника платформе, различити извори вијести и промјене тржишног периода могу унијети шум или систематску пристрасност у циљне ознаке.

Формиране су двије независне стратегије подјеле. Насумична подјела користи параметар *seed* вриједности 42 и односе приближно 80% за обуку, 10% за валидацију и 10%

за тестирање. Временска подјела сортира записе према времену објављивања, при чему најстарије вијести припадају скупу за обуку, наредни период валидационом скупу, а најновије вијести тест скупу.

Табела 2. Број примјера по стратегији подјеле

Стратегија	Обука	Валидација	Тест
Насумична	3.794	470	457
Временска	3.776	472	473

Временска подјела обухвата период од 2021. до 2025. године. Скуп за обуку завршава се 27. априла 2024, валидациони скуп 5. децембра 2024, а тест скуп обухвата период од 6. децембра 2024. до 23. маја 2025. На тај начин тестирање приближно одговара процјени генерализације на будуће вијести.



Слика 1: Дистрибуција класа по стратегији подјеле

На слици 1. видимо приказ броја вијести означених као *bullish*, *bearish* и *neutral* у скупу за обуку, валидацију и тест. Резултати су приказани одвојено за насумичну и временску подјелу, што омогућава поређење њихове структуре.

Насумична подјела задржава приближно сличан однос класа у сва три скупа. Код временске подјеле тест скуп садржи знатно већи удио неутралних и *bearish* вијести, док је *bullish* класа мање заступљена. Ова промјена дистрибуције представља један од разлога због којих је временска процјена строжа и реалистичнија.

6.5 Ознаке и припрема улаза

Изворна ознака `market_direction` мапирана је у нумеричку колону `labels` према следећем распореду:

Табела 3. Мапирање нумеричких ознака у циљне класе

Нумеричка ознака	Циљна класа
0	bullish
1	bearish
2	neutral

За улаз модела коришћена је колона текст из скупа података. Текст је токенизован токенизером базног FinBERT модела, уз максималну дужину од 256 токена. Дужи текстови су скраћени, а динамичко допуњавање примијењено је на нивоу пакета током обуке.

6.6 Поставка пројекта

Упоређене су три врсте модела. Први модел је оригинални FinBERT без додатне обуке. Други модел је TF-IDF са логистичком регресијом. За TF-IDF је најбоља вриједност параметра C изабрана на валидационом скупу између вриједности 0.1, 1.0 и 10.0. Након избора параметра, завршни TF-IDF модел трениран је искључиво на тренинг скупу. Валидациони скуп није коришћен за поновно тренирање модела.

Трећи модел је додатно обучени FinBERT. Обука је извршена за пет вриједности параметра seed: 43, 47, 53, 59 и 61 којим смо бирали насумичност тренинг података. Исте вриједности параметра seed коришћене су одвојено на насумичној и временској подјели, што даје укупно десет тренинга. Коришћене су три епохе, стопа учења $2e^{-5}$, пакет величине 16 и weight decay 0,01. Валидација је вршена након сваке епохе, а најбоља контролна тачка бирана је према макро F1 мјери.

6.7 Мјерила успјешности и статистичко поређење

Резултати су приказани помоћу тачности, макро прецизности, макро одзива, макро F1 и пондерисаног F1 резултата. За класу k , TP_k означава број тачно позитивних, FP_k број лажно позитивних, FN_k број лажно негативних примјера, N укупан број примјера, а C број класа:

$$\begin{aligned} \text{Тачност} &= \frac{\text{број тачних предикција}}{N} \\ P_k &= \frac{TP_k}{TP_k + FP_k}, \quad R_k = \frac{TP_k}{TP_k + FN_k} \\ F1_k &= 2 \cdot \frac{P_k R_k}{P_k + R_k}, \quad \text{МакроF1} = \frac{1}{C} \sum_{k=1}^C F1_k \end{aligned}$$

Макро F1 је главна метрика јер даје једнак значај свим класама и мање зависи од њихове неједнаке заступљености [25].


За поређење оригиналног и додатно обученог FinBERT модела коришћен је тачни двострани McNemar-ов тест [17]. Тест је примијењен на истим тест примјерима и пореди број случајева у којима је тачан само оригинални модел са бројем случајева у којима је тачан само додатно обучени модел. Праг статистичке значајности постављен је на $p < 0,05$.

6.8 Резултати

6.8.1 Поређење модела

Табела 4. Макро F1 резултати модела на двије стратегије подјеле

Подјела	Модел	Макро F1
Насумична	Оригинални FinBERT	0,4149
Насумична	TF-IDF + логистичка регресија	0,5298
Насумична	Додатно обучени FinBERT, средина $\pm$ SD	0,5761 $\pm$ 0,0089
Временска	Оригинални FinBERT	0,3688
Временска	TF-IDF + логистичка регресија	0,4109
Временска	Додатно обучени FinBERT, средина $\pm$ SD	0,4265 $\pm$ 0,0181



Слика 2: Поређење макро F1 резултата

На слици 2. видимо графикон који пореди макро F1 оригиналног FinBERT-а, TF-IDF модела са логистичком регресијом и додатно обученог FinBERT-а на насумичној и временској подјели. Виша вриједност означава бољи учинак када се подједнако узме у обзир успјешност препознавања сваке класе.


На насумичној подјели додатно обучени FinBERT остварио је средњи макро F1 од 0,5761, што је за 16,12 процентних поена више од оригиналног FinBERT-а. TF-IDF модел је такође надмашио оригинални FinBERT, са побољшањем од 11,49 процентних поена. То показује да сложенији модел није аутоматски најбоља референтна тачка без додатне обуке.

На временској подјели средњи макро F1 додатно обученог FinBERT модела износи 0,4265. То је за 5,77 процентних поена више од оригиналног FinBERT-а и за 1,56 процентних поена више од TF-IDF модела. Побољшање је, дакле, мање него на насумичној подјели, али додатно обучени модел задржава најбољи средњи резултат.

6.8.2 Варијабилност између вриједности параметра seed

На слици 3. свака тачка представља резултат једног покретања додатне обуке са различитим параметром *seed*. Графикон приказује колико се макро F1 мијења између пет покретања, одвојено за насумичну и временску подјелу.

Резултати насумичне подјеле су се кретали од 0,5673 до 0,5873, уз стандардну девијацију од 0,0089. Резултати временске подјеле кретали су се од 0,3978 до 0,4470, уз стандардну девијацију од 0,0181. Већа варијабилност резултата временске подјеле ука-



Слика 3: Варијабилност макро F1 према вриједности параметра seed

зује да је процјена осјетљивија на случајну иницијализацију и ток обуке када се модел суочава са временским помаком.


6.8.3 McNemar-ов тест

Табела 5. Резултати тачног McNemar-овог теста

Подјела	seed	Тачан само оригинални	Тачан само додатно обучени	p -вриједност	Значајно
Насумична	43	61	136	<0,001	Да
Насумична	47	53	139	<0,001	Да
Насумична	53	57	141	<0,001	Да
Насумична	59	61	139	<0,001	Да
Насумична	61	52	128	<0,001	Да
Временска	43	65	87	0,0882	Не
Временска	47	74	77	0,8708	Не
Временска	53	64	93	0,0251	Да
Временска	59	59	96	0,0037	Да
Временска	61	66	97	0,0185	Да

На слици 4. хоризонталне траке приказују резултате McNemar-овог теста за пет seed вриједности, засебно за насумичну и временску подјелу. Испрекидана линија означава праг статистичке значајности $p = 0,05$; трака која прелази праг показује мању p -вриједност и статистички значајну разлику између модела.

На насумичној подјели свих пет поређења показују статистички значајну разлику у корист додатно обученог модела. На временској подјели разлика је статистички значајна у три од пет понављања. У преостала два случаја резултат додатно обученог модела није статистички значајно различит од оригиналног модела. Ово показује да побољшање на будућим подацима није једнако стабилно као побољшање на насумичној подјели.



Слика 4: McNemar-ове р-вриједности

6.8.4 Матрице конфузије

На слици 5. имамо матрице конфузије које приказују како су оригинални FinBERT, TF-IDF модел и најбољи додатно обучени FinBERT класификовали вијести у три класе. Редови представљају стварне класе, а колоне предвиђене класе; бројеви на главној дијагонали показују тачна предвиђања, док остале ћелије приказују грешке и класе које је модел међусобно замијенио.


Матрице конфузије приказују стварне резултате, без ручно унесених вриједности. За додатно обучени модел приказана је вриједност параметра seed са највећим тест макро F1 резултатом у оквиру одговарајуће подјеле: seed = 47 за насумичну подјелу и seed = 59 за временску подјелу. Код временске подјеле видљиво је да сви модели теже раздвајају неутралне вијести од bullish и bearish класа, што је у складу са промијењеном дистрибуцијом класа у тест периоду.

6.9 Дискусија

Резултати показују да насумична подјела даје осјетно оптимистичнију процјену од временске подјеле. Средњи макро F1 додатно обученог модела пада са 0,5761 на 0,4265, односно за 14,96 процентних поена. Сличан пад видљив је и код TF-IDF модела, чији макро F1 пада са 0,5298 на 0,4109.

Овај пад може бити повезан са разликама у дистрибуцији класа, темама вијести и тржишном контексту између периода обуке и тестирања. Скуп за обуку чешће обухвата старије теме о блокчејну и сродним технологијама, док тест период обухвата новије теме, укључујући надоградњу Ethereum мреже Rector, ЕТФ теме, регулаторне догађаје и савремени Ethereum контекст. На основу резултата пројекта не може се доказати да је само једна од ових промјена узрок пада перформанси, али временска подјела реалистичније приказује задатак предвиђања будућих података.

Резултати такође указују на вриједност класичног референтног модела. TF-IDF са



Слика 5: Матрице конфузије

логистичком регресијом надмашио је оригинални FinBERT на обје подјеле. Додатно обучени FinBERT га је надмашио у просјеку, али је разлика на временској подјели била релативно мала.

6.10 Ограничења

Најважније ограничење јесте разлика између текстуалног сентимента који предвиђа оригинални FinBERT и тржишног правца изведеног из гласова корисника. Додатна обука зато истовремено представља доменско прилагођавање и промјену оперативно дефинисаног циља.

Ознаке могу садржати шум јер зависе од малог броја гласова, пристрасности корисника платформе, извора вијести и различитих тржишних периода. Насумична подјела може распоредити сличне верзије вијести или вијести о истом догађају у више скупова, због чега је временска процјена важна допунска провјера.

Даље ограничење представља један извор вијести, једноставан кључни филтер за издвајање Ethereum текстова и максимална дужина улаза од 256 токена. Резултати се зато не могу аутоматски генерализовати на све крипто вијести.

6.11 Поновљивост и структура резултата

Пројекат је могуће поновити помоћу нотебука и сачуваних скрипти на GitHub-у [33]. Сачувани су збирни резултати, предикције, матрице конфузије, McNemar-ови резултати и вриједности средине и стандардне девијације. Најбољи експортирани модели за насумичну и хронолошку подјелу налазе се у архиви.

7 Закључак

Вјештачка интелигенција представља широку област која се не може потпуно описати једном подјелом или једном техничком ознаком. У теоријском дијелу рада приказани су њен историјски развој, основни појам и границе, као и различити критеријуми класификације. Системи се могу разликовати према ширини способности, начину обраде информација, техничкој основи, сврси, степену аутономије и окружењу у којем се извршавају.

Преглед је показао да се ове категорије међусобно допуњују. Симболички системи користе експлицитна правила, док машинско учење и дубоке неуронске мреже обраде изводе из података. Генеративни модели стварају нове излазе, еволутивни алгоритми претражују простор могућих рјешења, а хибридни системи комбинују више приступа. Истовремено, техничка сложеност модела не одређује сама по себи његову способност, намјену или ниво аутономије.

FinBERT систем из практичног дијела припада уској вјештачкој интелигенцији, заснован је на дубоком учењу и трансформерској архитектури, има асистивну улогу и низак степен аутономије.

Резултати пројекта указују да додатна обука FinBERT-а побољшава класификацију ознака *bullish*, *bearish* и *neutral* у односу на оригинални FinBERT. На насумичној подјели средњи макро F1 износи $0,5761 \pm 0,0089$, а на временској $0,4265 \pm 0,0181$. Временска подјела даје знатно строжу процјену, док McNemar-ов тест показује статистички значајну разлику у свих пет понављања на насумичној и у три од пет понављања на временској подјели. TF-IDF са логистичком регресијом надмашује оригинални FinBERT на обје подјеле и представља важну класичну референтну тачку.

Ове резултате треба тумачити у границама циљног појма. Оригинални FinBERT предвиђа текстуални сентимент, док су циљне ознаке у коришћеном скупу изведене из гласова корисника платформе CryptoPanic и представљају перципирани тржишни правац. Додатна обука зато истовремено обухвата прилагођавање домену Ethereum-а и другачијм операционом циљу. Резултати указују на побољшање у условима спроведеног пројекта, али не доказују једнаку успјешност на свим будућим вијестима, изворима и тржишним периодима.

Простора за унапређење експеримента има у откривању приближних и семантичких дупликата у подацима, провјери ознака независном анотацијом, анализи утицаја броја гласова и извора вијести. Било би корисно одвојено моделирати текстуални сентимент, процјену заједнице и накнадно кретање тржишта.

8 Списак слика и табела

Списак слика

Слика 1. Расподјела циљних класа у обучном, валидационом и тестном скупу	27
Слика 2. Макро F1 резултати модела по стратегији подјеле	29
Слика 3. Варијабилност макро F1 резултата између поновљених обука	30
Слика 4. McNemar-ове p-вриједности и праг статистичке значајности	31
Слика 5. Матрице конфузије модела за насумичну и временску подјелу	32

Списак табела

Табела 1. Вишедимензионална класификација система примијењеног у практичном ди- јелу	22
Табела 2. Број примјера по стратегији подјеле	27
Табела 3. Мапирање нумеричких ознака у циљне класе	27
Табела 4. Макро F1 резултати модела на двије стратегије подјеле	28
Табела 5. Резултати тачног McNemar-овог теста	30

9 Литература

- [1] Araci, D. (2019). FinBERT: Financial sentiment analysis with pre-trained language models. *arXiv*. <https://arxiv.org/pdf/1908.10063>
- [2] Bahdanau, D., Cho, K., & Bengio, Y. (2015). Neural machine translation by jointly learning to align and translate. *International Conference on Learning Representations*. <https://arxiv.org/pdf/1409.0473>
- [3] Campbell, M., Hoane, A. J., & Hsu, F.-h. (2002). Deep Blue. *Artificial Intelligence*, 134(1–2), 57–83. [Open PDF](#)
- [4] Devlin, J., Chang, M.-W., Lee, K., & Toutanova, K. (2019). BERT: Pre-training of deep bi-directional transformers for language understanding. In *Proceedings of NAACL-HLT 2019* (pp. 4171–4186). Association for Computational Linguistics. <https://aclanthology.org/N19-1423.pdf>
- [5] Du, K., Xing, F., Mao, R., & Cambria, E. (2024). Financial sentiment analysis: Techniques and applications. *ACM Computing Surveys*, 56(9), Article 220, 1–42. <https://dl.acm.org/doi/pdf/10.1145/3649451>
- [6] Du, K., Zhao, Y., Mao, R., Xing, F., & Cambria, E. (2025). Natural language processing in finance: A survey. *Information Fusion*, 115, 102755. <https://2www.sentic.net/nlp-in-finance.pdf>
- [7] ExponentialScience. (2026). *DLT-Sentiment-News* [Dataset, CC BY-NC 4.0]. Hugging Face. Приступљено 7. септембра 2026. <https://huggingface.co/datasets/ExponentialScience/DLT-Sentiment-News>
- [8] He, K., Zhang, X., Ren, S., & Sun, J. (2016). Deep residual learning for image recognition. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition* (pp. 770–778). https://openaccess.thecvf.com/content_cvpr_2016/papers/He_Deep_Residual_Learning_CVPR_2016_paper.pdf
- [9] Hernandez Cruz, W., Devine, P., Vadgama, N., Tasca, P., & Xu, J. (2026). DLT-Corpus: A large-scale text collection for the distributed ledger technology domain. In *Proceedings of the 32nd ACM SIGKDD Conference on Knowledge Discovery and Data Mining (KDD '26)*. <https://arxiv.org/pdf/2602.22045>
- [10] Hochreiter, S., & Schmidhuber, J. (1997). Long short-term memory. *Neural Computation*, 9(8), 1735–1780. <https://oa.tib.eu/renate/server/api/core/bitstreams/4eeb2eda-9a99-47f0-9a4e-83a576d9f739/content>
- [11] Krizhevsky, A., Sutskever, I., & Hinton, G. E. (2012). ImageNet classification with deep convolutional neural networks. In *Advances in Neural Information Processing Systems 25*. [Open PDF](#)
- [12] Loughran, T., & McDonald, B. (2011). When is a liability not a liability? Textual analysis, dictionaries, and 10-Ks. *The Journal of Finance*, 66(1), 35–65. https://www.uts.edu.au/globalassets/sites/default/files/adg_cons2015_loughran-mcdonald-je-2011.pdf
- [13] Malo, P., Sinha, A., Korhonen, P., Wallenius, J., & Takala, P. (2014). Good debt or bad debt: Detecting semantic orientations in economic texts. *Journal of the American Society for Information Science and Technology*, 65(4), 782–796. <https://arxiv.org/pdf/1307.5336>

- [14] McCarthy, J., Minsky, M. L., Rochester, N., & Shannon, C. E. (1955). A proposal for the Dartmouth summer research project on artificial intelligence. *Dartmouth College*. <https://www-formal.stanford.edu/jmc/history/dartmouth/dartmouth.html>
- [15] Newell, A., & Shaw, J. C. (1957). Programming the Logic Theory Machine. In *Proceedings of the Western Joint Computer Conference* (pp. 230–240). https://iiif.library.cmu.edu/file/Newell_box00042_fld03525_doc0001/Newell_box00042_fld03525_doc0001.pdf
- [16] Newell, A., & Simon, H. A. (1956). The logic theory machine: A complex information processing system. RAND Corporation, Report P-868. https://iiif.library.cmu.edu/file/Simon_box00006_fld00406_bdl0001_doc0001/Simon_box00006_fld00406_bdl0001_doc0001.pdf
- [17] Pembury-Smith, M. Q. R., & Ruxton, G. D. (2020). Effective use of the McNemar test. *Behavioral Ecology and Sociobiology*, 74, 133. <https://link.springer.com/article/10.1007/s00265-020-02916-y>
- [18] Poole, D. L., & Mackworth, A. K. (2023). *Artificial intelligence: Foundations of computational agents* (3rd ed.). Cambridge University Press. Full text made available by the authors. <https://www.cs.ubc.ca/~poole/aibook/3e/html/ArtInt3e.html>
- [19] ProsusAI. (n.d.). *FinBERT* [Model card]. Hugging Face. <https://huggingface.co/ProsusAI/finbert>
- [20] Rosenblatt, F. (1958). The perceptron: A probabilistic model for information storage and organization in the brain. *Psychological Review*, 65(6), 386–408. https://web.stanford.edu/class/psych209a/ReadingsByDate/01_30/Rosenblatt58Perceptron.pdf
- [21] Rumelhart, D. E., Hinton, G. E., & Williams, R. J. (1986). Learning representations by back-propagating errors. *Nature*, 323, 533–536. <https://www.cs.toronto.edu/~hinton/absps/naturebp.pdf>
- [22] Samoil, S., López Cobo, M., Delipetrev, B., Martínez-Plumed, F., Gómez, E., & De Prato, G. (2021). *AI Watch: Defining artificial intelligence 2.0: Towards an operational definition and taxonomy for the AI landscape* (EUR 30873 EN). Publications Office of the European Union. https://publications.jrc.ec.europa.eu/repository/bitstream/JRC126426/jrc126426_ai_watch_defining_artificial_intelligence_2.0_final_29-10-2021.pdf
- [23] Shortliffe, E. H. (1977). MYCIN: A knowledge-based computer program applied to infectious diseases. In *Proceedings of the Annual Symposium on Computer Applications in Medical Care* (pp. 66–69). PubMed Central. <https://pmc.ncbi.nlm.nih.gov/articles/PMC2464549/>
- [24] Singh, R., & Gill, S. S. (2023). Edge AI: A survey. *Internet of Things and Cyber-Physical Systems*, 3, 71–92. <https://qmro.qmul.ac.uk/xmlui/bitstream/handle/123456789/85043/Gill%20Edge%20AI%20A%20survey%202023%20Published.pdf?sequence=2>
- [25] Sokolova, M., & Lapalme, G. (2009). A systematic analysis of performance measures for classification tasks. *Information Processing & Management*, 45(4), 427–437. <https://rali.iro.umontreal.ca/rali/sites/default/files/publis/SokolovaLapalme-JIPM09.pdf>
- [26] Toosi, A. N., Bottino, A. G., Saboury, B., Siegel, E., & Rahmim, A. (2021). A brief history of AI: How to prevent another winter (A critical review). *PET Clinics*, 16(4), 449–469. <https://doi.org/10.1016/j.petcl.2021.04.001>

[//arxiv.org/pdf/2109.01517](https://arxiv.org/pdf/2109.01517)

[27] Turing, A. M. (1950). Computing machinery and intelligence. *Mind*, 59(236), 433–460. <https://www.cs.swarthmore.edu/~meeden/cs63/f07/TuringArticle.pdf>

[28] Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., & Polosukhin, I. (2017). Attention is all you need. In *Advances in Neural Information Processing Systems* 30. <https://arxiv.org/pdf/1706.03762>

[29] Wu, S., Irsoy, O., Lu, S., Dabrowski, V., Dredze, M., Gehrmann, S., Kambadur, P., Rosenberg, D., & Mann, G. (2023). BloombergGPT: A large language model for finance. *arXiv*. <https://arxiv.org/pdf/2303.17564>

[30] Yang, H., Liu, X. Y., & Wang, C. D. (2023). FinGPT: Open-source financial large language models. *arXiv*. <https://arxiv.org/pdf/2306.06031>

[31] Yang, Y., Uy, M. C. S., & Huang, A. (2020). FinBERT: A pretrained language model for financial communications. *arXiv*. <https://arxiv.org/pdf/2006.08097>

[32] Zadeh, L. A. (1965). Fuzzy sets. *Information and Control*, 8(3), 338–353. <https://home.iitk.ac.in/~avrs/ManyValuedLogic/Zadeh-1965.pdf>

[33] <https://github.com/radioactivus/diplomski>